Πανεπιστήμιο Δυτικής Αττικής
Σχολή Μηχανικών
Τμήμα Μηχανικών Πληροφορικής και Υπολογιστών

Διαχείριση δεδομένων
Μεγάλης κλίμακας

Ομάδα 04

1. Εισαγωγή

Στην παρούσα εργασία, μελετάμε και αναλύουμε το σύνολο δεδομένων εγκληματικότητας της πόλης του Los Angeles από το 2020 μέχρι και το 2025, χρησιμοποιώντας τεχνικές επεξεργασίας και ανάλυσης μεγάλης κλίμακας με Python. Στόχος της εργασίας είναι η εξαγωγή χωρικών, χρονικών και δημογραφικών μοτίβων, όπως επίσης και η μηνιαία πρόβλεψη εγκλημάτων για τον επόμενο χρόνο.

2. Ορισμός προβλήματος και κίνητρο

Το κεντρικό ερώτημα είναι η κατανόηση και πρόβλεψη της εγκληματικότητας σε επίπεδο περιοχής, χρονικής συγκέντρωσης και δημογραφικών χαρακτηριστικών θυμάτων, με σκοπό:

- Βελτιστοποίηση επιχειρησιακών πόρων: Οι αστυνομία μέσα από τις έρευνες μπορεί να δραστηριοποιείται περισσότερο σε περιοχές με μεγαλύτερη εγκληματικότητα, καθώς και βάση της ώρας.

- Υποστήριξη ερευνητών & δημοσιογράφων: παροχή στοιχείων για δημοσιογραφικές έρευνες ή ακαδημαϊκές μελέτες.

- Παράδειγμα εφαρμογής: αύξηση περιπολιών σε περιοχές όπου αναμένεται αιχμή βάσει προβλέψεων (π.χ. επόμενος μήνας).

3. Σύντομη περιγραφή συνόλου δεδομένων

Χρησιμοποιούμε το αρχείο Crime_Data_from_2020_to_Present.csv που πήραμε από το Kaggle, το οποί περιλαμβάνει εγγραφές όπως:

- Crm Cd Desc: περιγραφή τύπου εγκλήματος
- Γεωγραφικές συντεταγμένες: LAT, LON
- Ημερομηνία/Ώρα: DATE OCC, TIME OCC
- AREA NAME: τοπική περιοχή
- Θύματα: ηλικία (Vict Age), φύλο (Vict Sex)

4. Μέθοδος ανάλυσης δεδομένων

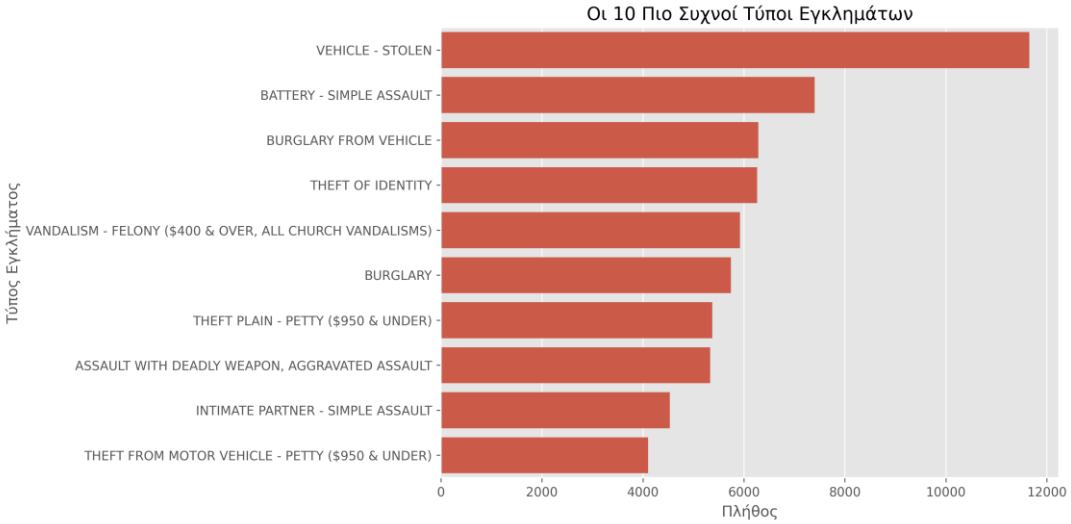
Η διαδικασία περιελάμβανε τα εξής στάδια:

- Προεπεξεργασία:
  - Μετατροπή σε datetime, εξαγωγή Year/Month/Day/Hour
  - Κατηγοριοποίηση περιόδων ημέρας ('Νύχτα', 'Πρωί', 'Απόγευμα', 'Βράδυ')
  - Διαχείριση ελλειπουσών τιμών: αριθμητικά → μέσος όρος, κατηγορικά → συχνότερη τιμή project.

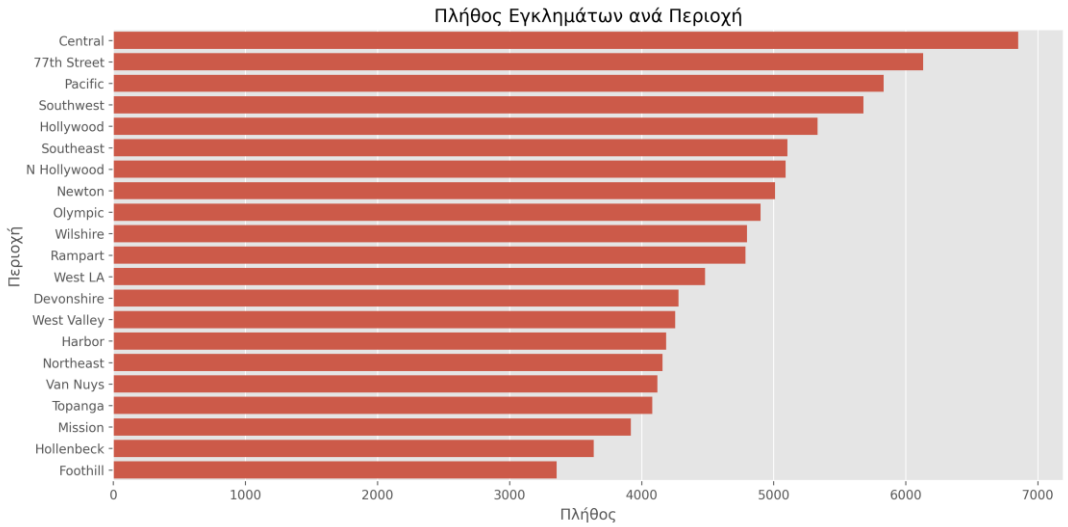
- Εξερευνητική Ανάλυση (EDA)
  - Κατανομή τύπων εγκλήματος, περιοχών, ωρών, ημερών, δημογραφικών.
  - Οπτικοποιήσεις με barplots, γραφήματα γραμμής, heatmap.

- Προχωρημένες Τεχνικές
  - Clustering (K-means) σε δειγματοληπτικά γεωγραφικά σημεία (≤20.000) για εντοπισμό περιοχών με μεγαλύτερη εγκληματικότητα.
  - PCA (2 κύριες συνιστώσες) για μείωση διαστατικότητας σε αριθμητικά χαρακτηριστικά.
  - Πρόβλεψη με απλή γραμμική παλινδρόμηση σε μηνιαία συγκεντρωμένα δεδομένα.

- Αξιολόγηση
  - Μέτρηση χρόνων εκτέλεσης, R^2 score για το πρότυπο παλινδρόμησης (>0.7 θεωρείται καλή προσαρμογή), αδράνεια (inertia) για clustering.**5. Πειραματικά αποτελέσματα και αποτίμησή τους**



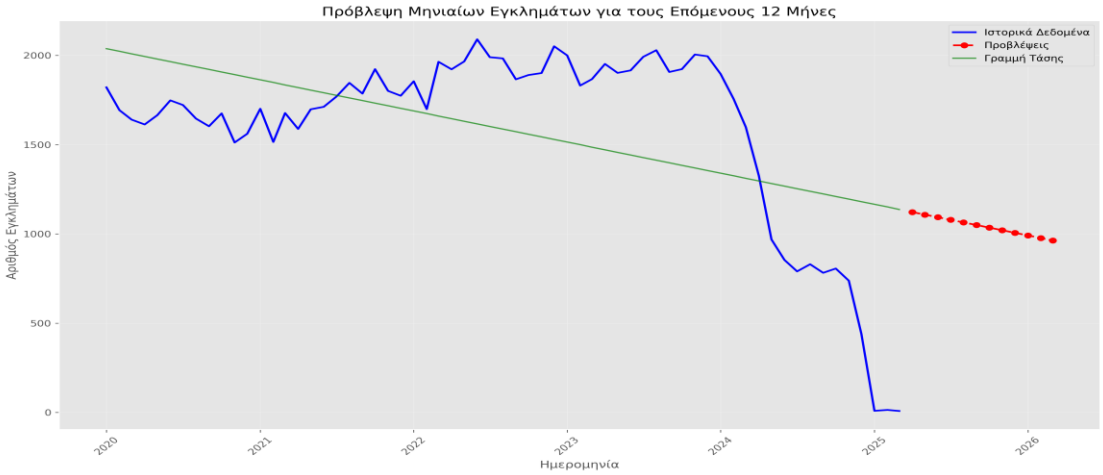
Οι 10 πιο συχνοί τύποι εγκλημάτων στο Λος Άντζελες την περίοδο 2020-25.



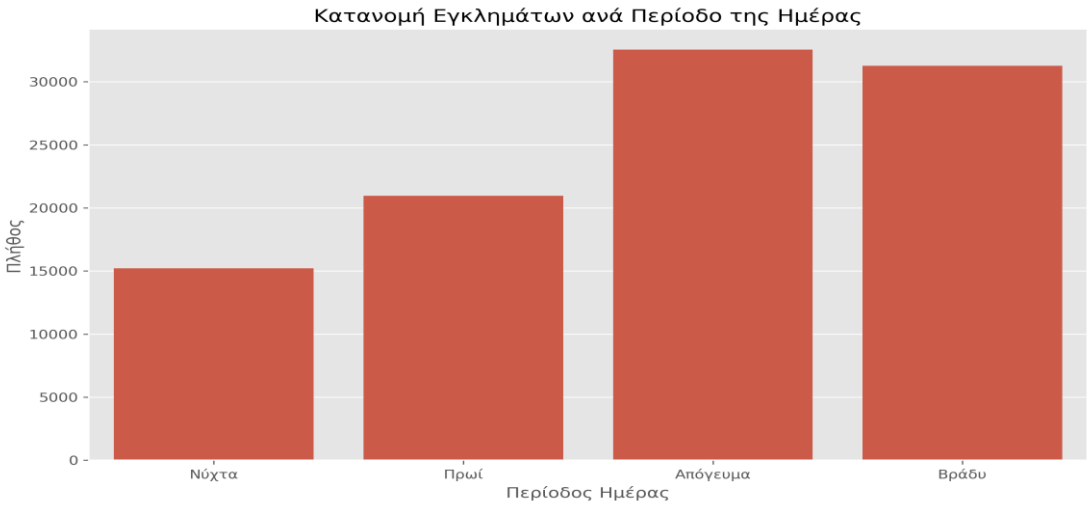
Παρουσίαση του πλήθους των εγκλημάτων ανά περιοχή.



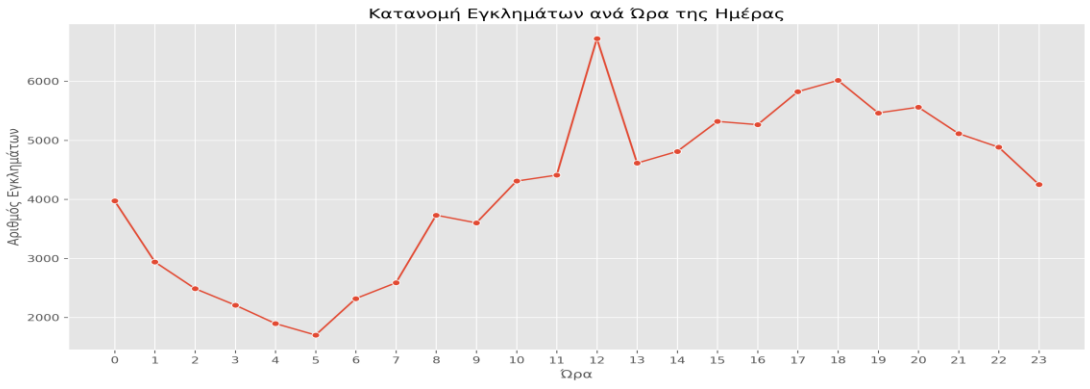
Η τάση της εγκληματικότητας μέσα σε 5 χρόνια.



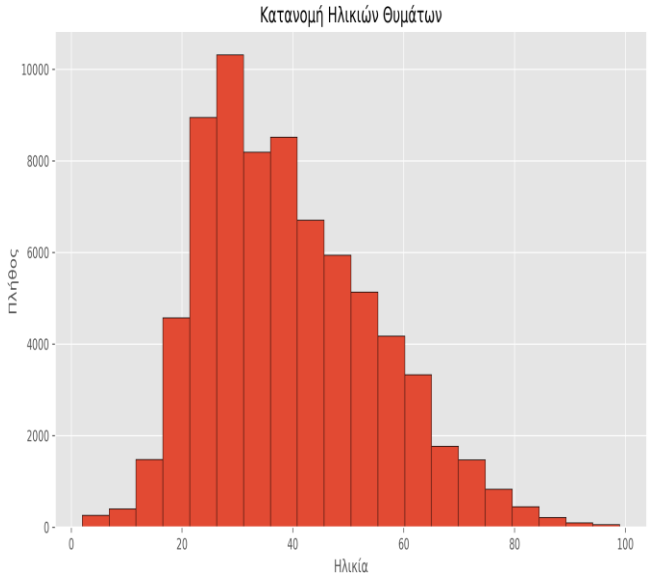
Πτωτική πρόβλεψη μηνιαίων εγκλημάτων για τον επόμενο χρόνο.

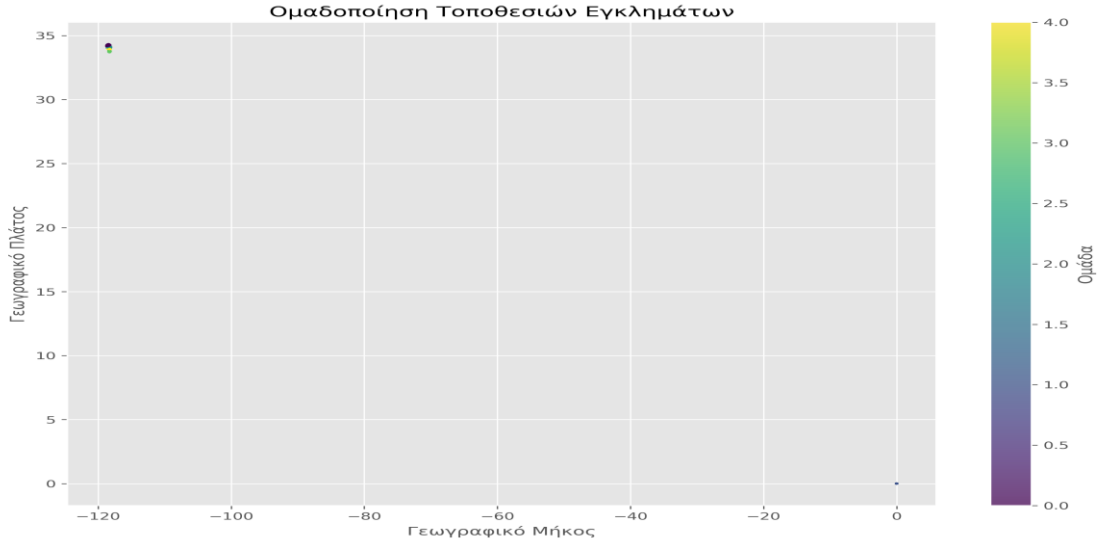


Παρουσίαση του πλήθους των εγκλημάτων ανά χρονική περίοδο μέσα στην ημέρα.

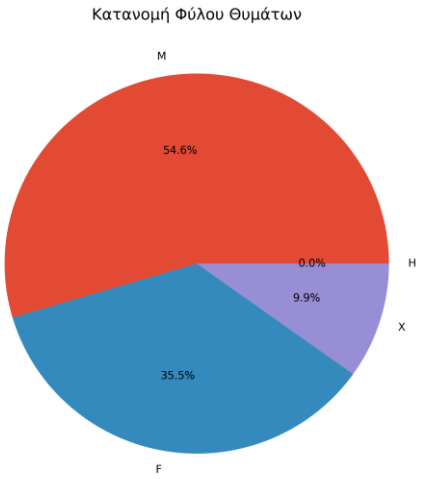


Κατανομή των εγκλημάτων ανά ώρα της ημέρας.



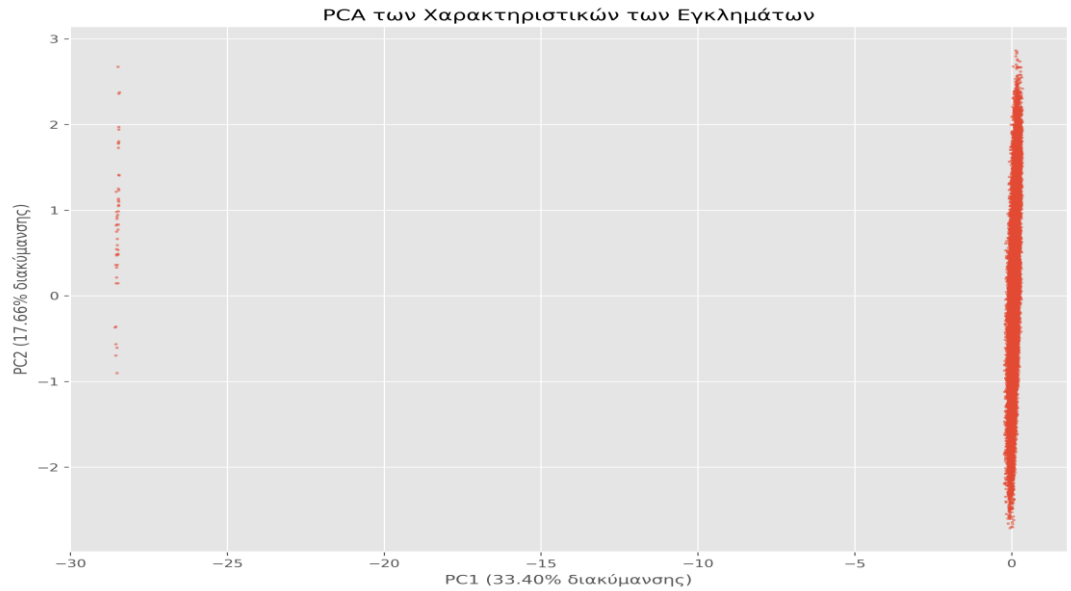


Ομαδοποίηση των τοποθεσιών όπου έγιναν τα εγκλήματα.

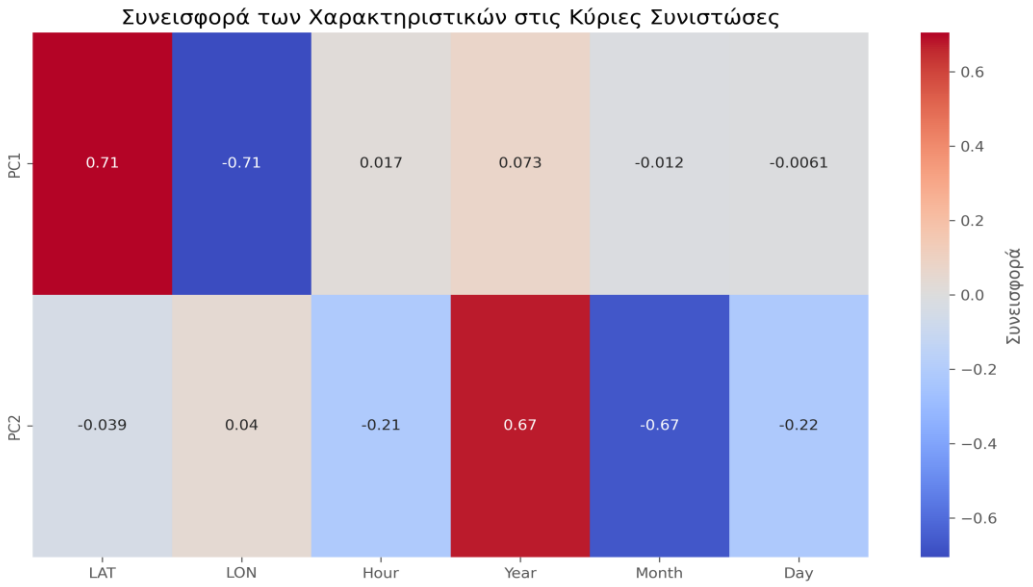


Κατάταξη των θυμάτων ανα ηλικία και πλήθος

Κατάταξη των θυμάτων ανά φύλο



Η ανάλυση κύριων συνιστωσών



Ο χάρτης συσχετίσεων

5. Συμπεράσματα

Η συνδυασμένη χρήση EDA, clustering, PCA και γραμμικής παλινδρόμησης προσφέρει πλήρη εικόνα των χωρικών, χρονικών και δημογραφικών μοτίβων εγκληματικότητας. Τα απλά γραμμικά μοντέλα προβολής αποδίδουν ικανοποιητικά ($R^2 \approx 0.7$), αλλά μελλοντικά η εργασία θα μπορούσε να επεκταθεί σε πιο σύνθετες μεθόδους (ARIMA, LSTM) και γεωχωρικές απεικονίσεις (π.χ. χάρτες heatmap).