

Εργασία Δεδομένων

Λειτουργίες

- Χωρίζονται σε 2 βασικές κατηγορίες
 - Περιγραφικές: Χαρακτηρισμός των βασικών ιδιοτήτων των δεδομένων που βασίζονται
 - Προγνωστικές: εξαγωγή συμπεράσματος στα υπάρχοντα δεδομένα για την παραγωγή προβλέψεων.

- Βασικές λειτουργίες που θα δούμε στο μάθημα:

- Κατηγοροποίηση
- Ομαδοποίηση
- Εύρεση κανόνων συσχετίσης

Κανόνες Συσχετίσης Παράδειγμα

- Είσοδος: Δεδομένα συναλλαγών - αγορασμένα αντικείμενα
- Εύρεση κανονών που εκφράζουν τις συσχετίσεις μεταξύ της ύπαρξης αντικειμένων κατά τις συναλλαγές

Περιγραφή Δεδομένων

- Μέση τιμή (mean): ευαίσθητη σε ακραία δεδομένα

$$\text{mean}(x) = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- Ενδιαμεση (median):

$$\text{median}(x) = \begin{cases} x_{(n+1)} \\ \frac{1}{2}(x_{(n)} + x_{(n+1)}) \end{cases}$$

- Επικρατούσα τιμή (Mode): η πιο συχνή τιμή

- Διασπορά τυπική απόκλιση: ευαίσθητη σε ακραία δεδομένα

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Τεταρτημορία Q_1 και Q_3

- Έστω το σύνολο ταξινομημένων δεδομένων

$$x(1), x(2), \dots, x(n)$$

Υπολογίζουμε θέσεις $k_1 = 25(n+1)/100$ και $k_3 = 75(n+1)/100$

Τα ακέραια μέρη k_1 και k_3 α₁ και α₃

Τα δεκαδικά μέρη k_1 , k_3 β₁ και β₃

Οι τιμές υπολογίζονται ως εξής:

$$Q_1 = x(a_1) + 0, b_1 \cdot (x(a_1+1) - x(a_1))$$

$$Q_3 = x(a_3) + 0, b_3 \cdot (x(a_3+1) - x(a_3))$$

Διασπορά των Δεδομένων - Θηκογράμματα

Τεταρτημορία (Quantiles): $Q_1(25\%), Q_3(75\%)$

Ενδοτεταρτημοριακό εύρος: $IQR = Q_3 - Q_1$

Περιβληφή περιε αριθμών: min, Q_1 , max, Q_3 , μέση

Θηκογράμματα: Τα όρια του παραλληλογράμμου είναι τα Q_1 και Q_3 , προστίθενται η μέγιστη/ελάχιστη τιμή και τα ακραία δεδομένα

Ακραίο δεδομένο (outlier): συνήθως, μια τιμή υψηλότερη/χαμηλότερη από $1,5 \times IQR$: Άνω Όριο = $Q_3 + 1,5 \times IQR$

Κάτω όριο = $Q_1 - 1,5 \times IQR$

Παράδειγμα:

- Μινοποι οι αναλυθείσες μετρήσεις ύψους (σε εκατοστόμετρα) 8 ατόμων:

182, 156, 164, 135, 191, 179, 185, 182

$x(1), x(2), \dots$

- (α) Να υπολογιστούν οι στατικές τιμές και να δημιουργηθεί το θηκογράμματα (box plot)

- (β) Να χρησιμοποιηθεί οποιαδήποτε τεχνική επιθυμεί κάθε φοιτητής για να βρεθούν τα ακραία δεδομένα.

α)

(α) Μέση τιμή: $\bar{x} = \frac{1}{8} \cdot \sum_{i=1}^8 x(i) = \frac{1}{8} [135 + 156 + \dots + 191] \Leftrightarrow 171,75$

β) $\sigma = \sqrt{\frac{1}{8} \sum_{i=1}^8 (x_i - 171,75)^2} \Leftrightarrow \sigma = 187,75$

Τυπική απόκλιση

γ) Q_2 : Median, Εφόσον η=αρτίος υπολογίζουμε το ημιαθροίσμα των μεσαίων τιμών

από θεωρία συνός median: $\begin{cases} x_{(n+1)} & \text{if } n \text{ is odd} \\ \frac{x_{(n)} + x_{(n+1)}}{2} & \text{even} \end{cases}$

$$Q_2 = \frac{x(4) + x(5)}{2} = \frac{179 + 182}{2} = Q_2 = 180,5$$

β) Τύπος υπολογισμού των Q_1 και Q_3

Αυξούσα σειρά

L: 135, 156, 164, 179, 182, 182, 185, 191

$\begin{matrix} x(1) & x(2) & x(3) & x(4) & x(5) & x(6) & x(7) & x(8) \\ \downarrow & \downarrow & \downarrow & \downarrow & \downarrow & \downarrow & \downarrow & \downarrow \end{matrix}$

$$k_1 = \frac{25}{100} (n+1) = \frac{1}{4} \cdot 9 = 2,25 \text{ άρα } a_1 = 2, b_1 = 25$$

$$k_3 = \frac{75}{100} (n+1) = \frac{3}{4} \cdot 9 = 6,75 \text{ άρα } a_3 = 6, b_3 = 75$$

$$Q_1 = x(a_1) + 0, b_1 \cdot [x(a_1+1) - x(a_1)] = x(2) + 0,25 \cdot (x(3) - x(2)) = 156 + \frac{1}{4} [164 - 156] = 156 + 8/4 \Rightarrow \boxed{Q_1 = 158}$$

$$Q_3 = x(a_3) + 0,75 [x(a_3+1) - x(a_3)] = 182 + \frac{3}{4} [185 - 182] = 182 + 9/4 \Rightarrow Q_3 = 184,25$$

min = 135, max = 191

δ) Ενδοτεταρτημοριακό εύρος

$$IQR = Q_3 - Q_1 = 184,25 - 158 = 26,25$$

$$1,5 \cdot IQR = 39,375$$

• Outlier < $Q_1 - 39,375 = 118,625 < \min$

Δεν υπάρχει ακραίο σημείο στα αριστερά

• Outlier > $Q_3 + 39,375 = 223,625 > \max$

Δεν υπάρχει ακραίο σημείο στα δεξιά

box plot, Θηκογράμματα

