

Μαθημα 3.

Χειρισμός με τα δεδομένα

- Ποιοτικά
- Κβάντωση
- Μείωση μεγέθους
- Μέτρα απόστασης

Ανωμαλίες (ακραίες) και ασύνητες τιμές

- Ανωμαλίες τιμές: Δεν ακολουθούν την κατανομή των τιμών των υπολοίπων αντικείμενων
- Τα αντικείμενα με ανωμαλίες τιμές καλούνται outliers
- Ποιο συνήθισμένη αιτία: Λαθιά κατά την εισαγωγή τιμών.

Μετασχηματισμός Δεδομένων

- Ονομάζουμε την εφαρμογή κάποιας συνάρτησης επί των τιμών μιας ιδιότητας, συνήθως μετασχηματίζουμε τις τιμές μιας αριθμητικής ιδιότητας που έχει μεγάλες ή μικρότερες τιμές

- Τυποποίηση $X = \frac{X - \bar{X}}{\sigma}$


- μετασχηματισμός min-max: $X = \frac{X - X_{\min}}{X_{\max} - X_{\min}} (X'_{\max} - X'_{\min}) + X'_{\min}$

- Κανονικοποίηση με δεκαδική κλίμακα:

$$X' = X / 10^j$$

Χειρισμός ελλείπων δεδομένων.

1	2	3
Φεβ25, 2, 7	Σεπ25, 3, 5	Φεβ1, 5
		Σεπ26, 9, 6



$$(1, 3.5) = (X_1, y_1)$$

$$(3, 4.6) = (X_2, y_2)$$

$$y = Ax + B$$

$$y_2 - y_1 = \frac{y_2 - y_1}{x_2 - x_1} (x - x_1) \Rightarrow$$

$$y - 3.5 = \frac{4.6 - 3.5}{3 - 1} (x - 1) \Leftrightarrow \text{Για } x=2$$

$$y - 3.5 = \frac{1.1}{2} \Leftrightarrow$$

$$y = \frac{1.1}{2} + 3.5 = \frac{1.1 + 7}{2} = \frac{8.1}{2} = 4.05$$

Μετασχηματισμός Δεδομένων

$$[X_{\min}, X_{\max}] \rightarrow [X'_{\min}, X'_{\max}]$$

$$X' = Ax + B \quad \Delta = \begin{vmatrix} X_{\min} & 1 \\ X_{\max} & 1 \end{vmatrix} = X_{\min} - X_{\max}$$

$$\begin{cases} X_{\min} = Ax_{\min} + B \\ X_{\max} = Ax_{\max} + B \end{cases} \Rightarrow \begin{cases} X'_{\min} \\ X'_{\max} \end{cases} \Delta_1 = \begin{vmatrix} X'_{\min} & 1 \\ X'_{\max} & 1 \end{vmatrix} = X'_{\min} - X'_{\max}$$

$$A = \frac{\Delta_1}{\Delta_0} = \frac{X'_{\min} - X'_{\max}}{X_{\min} - X_{\max}} \quad \Delta_2 = \begin{vmatrix} X_{\min} & X'_{\min} \\ X_{\max} & X'_{\max} \end{vmatrix} = X_{\min} X'_{\max} - X_{\max} X'_{\min}$$

$$\frac{X'_{\max} - X'_{\min}}{X_{\max} - X_{\min}}$$

$$B = \frac{\Delta_2}{\Delta_0} = \frac{X_{\min} X'_{\max} - X_{\max} X'_{\min}}{X_{\min} - X_{\max}} = \frac{X_{\max} X'_{\min} - X'_{\min} X_{\max}}{X_{\max} - X_{\min}}$$

$$X = [3, 5, 7, 9, 11]$$

$$\bar{X} = 7$$

$$X' = [3-7, 5-7, 7-7, 9-7, 11-7] = [-4, -2, 0, 2, 4]$$

$$\bar{X}' = \frac{-4 - 2 - 0 + 2 + 4}{5} = 0$$

Ανωμαλίες ή Ακραίες τιμές (Outliers):